- **O que vamos aprender:**
  - utilizar a bilioteca Pandas - a mais utilizada no mundo para análise de dados
  - carregar dados de um arquivo Excel
  - fazer análise exploratória nos dados
  - gerar estatísticas das colunas quantitativas
  - gerar gráficos interativos
- **Projeto da aula:**
  - Realizar uma análise de dados sobre uma base de 70.000 linhas de uma rede de lojas de venda de Açaí.

Carregando os dados do arquivo Excel

Importando a biblioteca

A biblioteca **Pandas** já vem pré-instalada no Anaconda, então só precisamos importá-la.

In [1]:
```
import pandas as pd
```

In [2]:
```
# lendo os dados (nesse código, o arquivo Excel precisa estar na mesma pasta)
dados = pd.read_excel("vendas.xlsx")
```

Análise Exploratória

Verificando se os dados foram carregados corretamente

Para verificar se os dados foram carregados corretamente, podemos utilizar dois métodos do Pandas:

- **head()**: mostra as primeiras linhas do conjunto de dados
- **tail()**: mostra as últimas linhas do conjunto de dados

In [3]:
```
dados.head()
```

Out[3]:

	id_pedido	data	loja	cidade	estado	regiao	tamanho	local_consumo	preco	forma_pagamento	ano_m
0	PED1	2021-06-21	Loja 4	Santos	São Paulo	Sudeste	200ml	Delivery	5	Crédito	2021-

1	PED2	2021-04-17	Loja 2	Niterói	Rio de Janeiro	Sudeste	200ml	Consumo no local	5	Pix	2021-
2	PED3	2022-12-12	Loja 1	Fortaleza	Ceará	Nordeste	500ml	Delivery	9	Pix	2022-
3	PED4	2022-03-09	Loja 2	Niterói	Rio de Janeiro	Sudeste	300ml	Consumo no local	7	Débito	2022-
4	PED5	2022-11-28	Loja 4	Santos	São Paulo	Sudeste	700ml	Delivery	11	Débito	2022-

In [4]:
```
dados.tail()
```

Out[4]:

	id_pedido	data	loja	cidade	estado	regiao	tamanho	local_consumo	preco	forma_pagamento
69995	PED69996	2020-12-03	Loja 5	São Paulo	São Paulo	Sudeste	300ml	Consumo no local	7	Dinheiro
69996	PED69997	2021-06-01	Loja 6	Florianópolis	Santa Catarina	Sul	700ml	Consumo no local	11	Pix
69997	PED69998	2022-07-14	Loja 6	Florianópolis	Santa Catarina	Sul	700ml	Delivery	11	Dinheiro
69998	PED69999	2021-06-01	Loja 6	Florianópolis	Santa Catarina	Sul	500ml	Consumo no local	9	Pix
69999	PED70000	2022-07-10	Loja 2	Niterói	Rio de Janeiro	Sudeste	700ml	Consumo no local	11	Dinheiro

Quantidade de linhas e colunas

- Podemos usar a propriedade **shape** para verificar a quantidade de linhas e colunas. O primeiro valor é a quantidade de **linhas** e o segundo a de **colunas**.

In [5]:
```
dados.shape
```

Out[5]:
```
(70000, 11)
```

Informações sobre as colunas

O Pandas tem um método muito poderoso para gerar informações importantes sobre o conjunto de dados:**info()**.

In [6]:
```
dados.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 70000 entries, 0 to 69999
Data columns (total 11 columns):
 #   Column           Non-Null Count  Dtype         
---  ------           --------------  -----         
 0   id_pedido        70000 non-null  object        
 1   data             70000 non-null  datetime64[ns]
 2   loja             70000 non-null  object        
 3   cidade           70000 non-null  object        
 4   estado           70000 non-null  object        
 5   regiao           70000 non-null  object        
 6   tamanho          70000 non-null  object        
 7   local_consumo    70000 non-null  object        
 8   preco            70000 non-null  int64         
```

```
 9   forma_pagamento  70000 non-null  object
 10  ano_mes          70000 non-null  object
dtypes: datetime64[ns](1), int64(1), object(9)
memory usage: 5.9+ MB
```

Gerando estatísticas

O método **describe()** gera estatísticas sobre todas as colunas quantitativas.

In [7]:
```
dados.describe()
```

Out[7]:

	preco
count	70000.000000
mean	9.009571
std	2.831874
min	5.000000
25%	7.000000
50%	9.000000
75%	11.000000
max	13.000000

Acessando uma coluna

Para acessar uma coluna, podemos utilizar a notação de colchetes, passando o nome da coluna desejada.

Caso o nome da coluna não possua espaços em branco de nem caracteres especiais, podemos acessar também com a notação de ponto.

In [8]:
```
dados['loja']
```

Out[8]:
```
0         Loja 4
1         Loja 2
2         Loja 1
3         Loja 2
4         Loja 4
           ...
69995     Loja 5
69996     Loja 6
69997     Loja 6
69998     Loja 6
69999     Loja 2
Name: loja, Length: 70000, dtype: object
```

In [9]:
```
dados.loja
```

Out[9]:
```
0         Loja 4
1         Loja 2
2         Loja 1
3         Loja 2
4         Loja 4
           ...
69995     Loja 5
69996     Loja 6
69997     Loja 6
69998     Loja 6
```

```
69999    Loja 2
Name: loja, Length: 70000, dtype: object
```

Obtendo os únicos de uma coluna

Para obter os valores únicos de uma coluna, utilizamos o método **unique()**.

In [10]:
```
dados['loja'].unique()
```

Out[10]:
```
array(['Loja 4', 'Loja 2', 'Loja 1', 'Loja 6', 'Loja 3', 'Loja 5'],
      dtype=object)
```

Contagem de valores

Para fazer a contagem de valores de uma coluna, podemos utilizar o método **value_counts()**.

Podemos obter também o valor relativo, utilizando o parâmetro **normalize=True**.

In [11]:
```
dados['loja'].value_counts()
```

Out[11]:
```
Loja 6    16648
Loja 3    12367
Loja 1    12344
Loja 5    12177
Loja 2     8318
Loja 4     8146
Name: loja, dtype: int64
```

In [12]:
```
dados['loja'].value_counts(normalize=True)
```

Out[12]:
```
Loja 6    0.237829
Loja 3    0.176671
Loja 1    0.176343
Loja 5    0.173957
Loja 2    0.118829
Loja 4    0.116371
Name: loja, dtype: float64
```

Agrupando dados

O método **groupby()** realiza o agrupamento de dados por determinada coluna.

Sempre que utilizarmos o **groupby()**, precisamos definir o **método de agregação** que será usado.

In [13]:
```
# faturamento por loja
dados.groupby('loja').sum()
```

Out[13]:

loja	preco
Loja 1	111042
Loja 2	74700
Loja 3	111709
Loja 4	73598
Loja 5	109393
Loja 6	150228

In [14]:
```
# média de faturament por loja (ticket médio)
dados.groupby('loja').mean()
```

Out[14]:

loja	preco
Loja 1	8.995625
Loja 2	8.980524
Loja 3	9.032829
Loja 4	9.034864
Loja 5	8.983576
Loja 6	9.023787

Gráficos

Instalando e importando a biblioteca de gráficos

Para gerar os gráficos vamos utilizar a biblioteca **Plotly Express**.

In [16]:
```
import plotly_express as px
```

Contagem de pedidos por loja

In [17]:
```
px.histogram(dados, x="loja", color="regiao", text_auto=True)
```

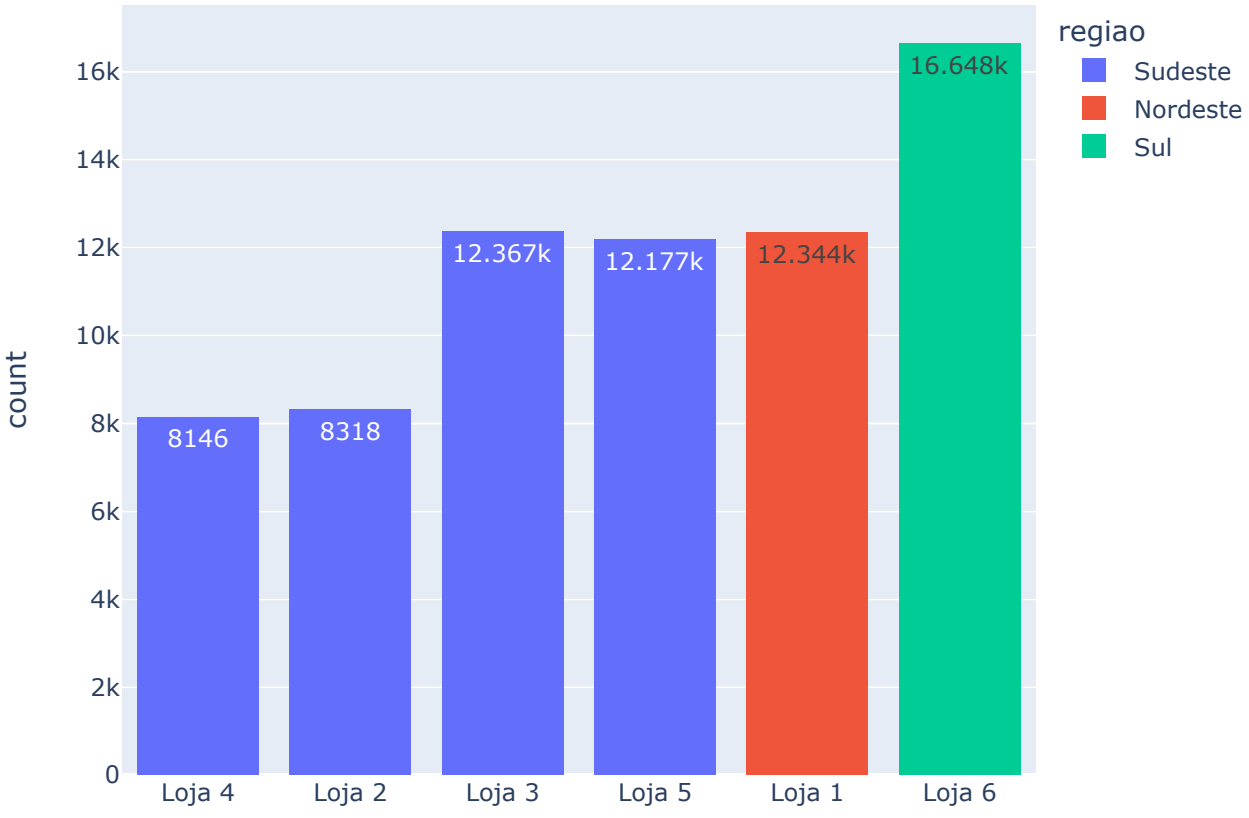

loja

Criando múltiplos gráficos e gerando seus respectivos arquivos HTML

In [18]:
```
colunas = ['loja', 'cidade', 'estado', 'tamanho', 'local_consumo']

for coluna in colunas:
    fig = px.histogram(dados, x=coluna, y='preco', color='forma_pagamento', text_auto=Tr
    fig.write_html(f"faturamento por {coluna}.html")
    fig.show()
```

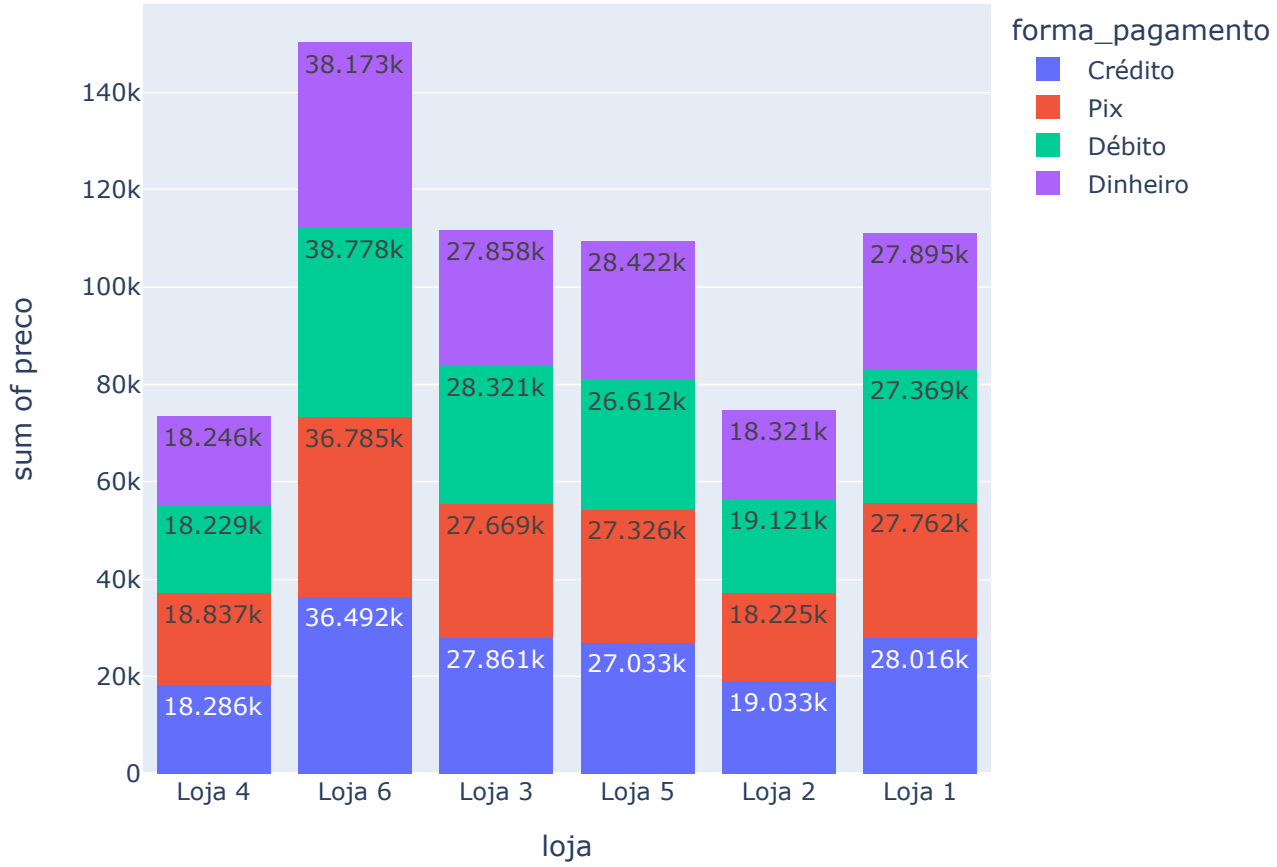

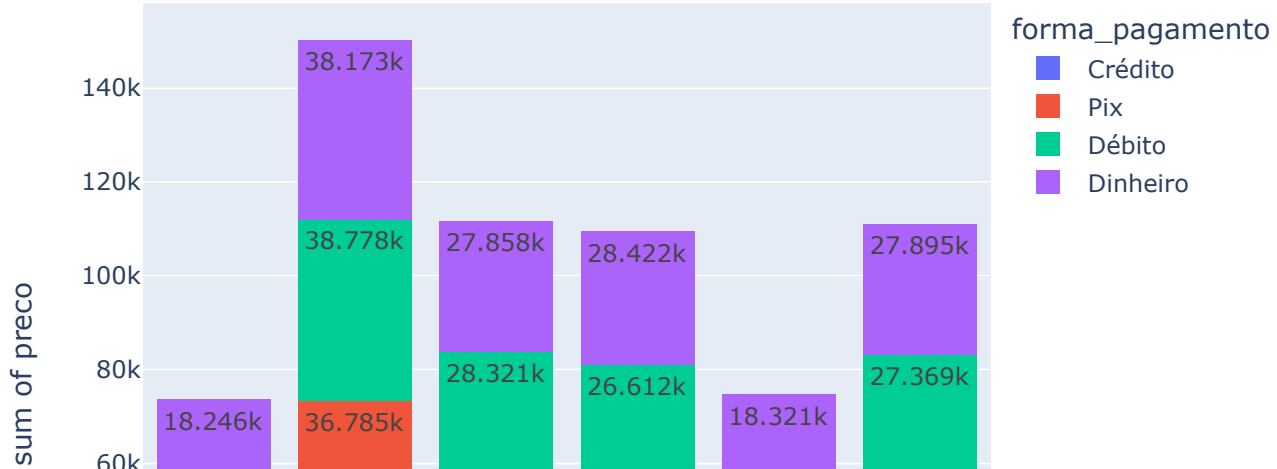

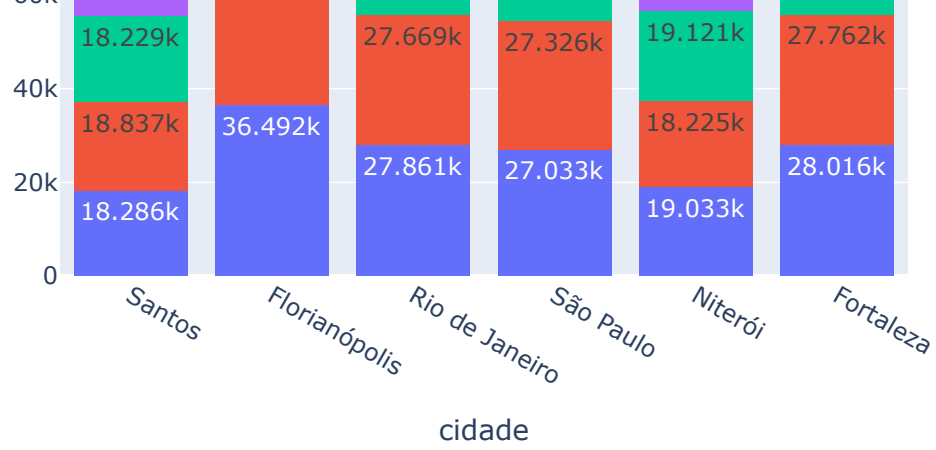
18.229k
18.837k
18.286k
36.492k
27.669k
27.861k
27.326k
27.033k
19.121k
18.225k
19.033k
27.762k
28.016k
40k
20k
0
Santos
Florianópolis
Rio de Janeiro
São Paulo
Niterói
Fortaleza
cidade

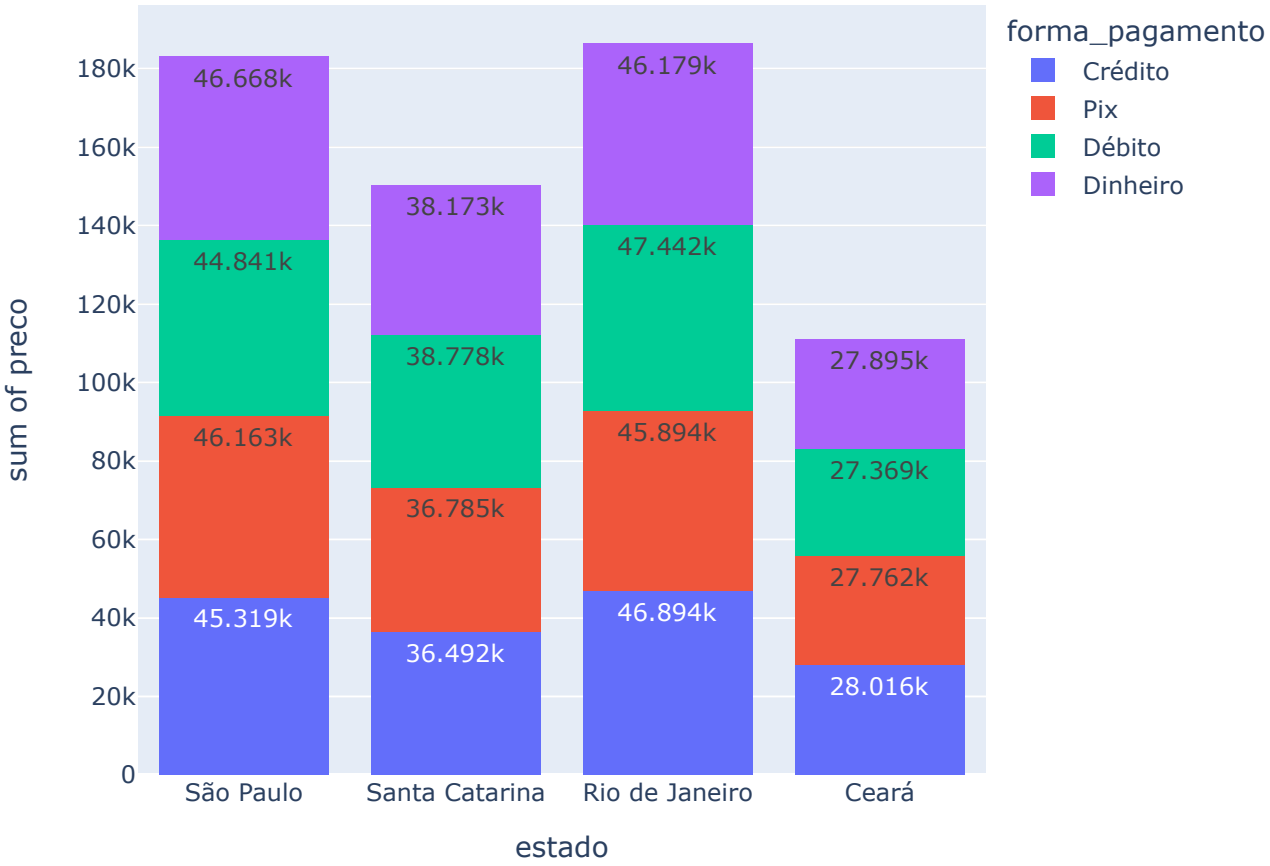
forma_pagamento
Crédito
Pix
Débito
Dinheiro
sum of preco
180k
160k
140k
120k
100k
80k
60k
40k
20k
0
46.668k
44.841k
46.163k
45.319k
38.173k
38.778k
36.785k
36.492k
46.179k
47.442k
45.894k
46.894k
27.895k
27.369k
27.762k
28.016k
São Paulo
Santa Catarina
Rio de Janeiro
Ceará
estado

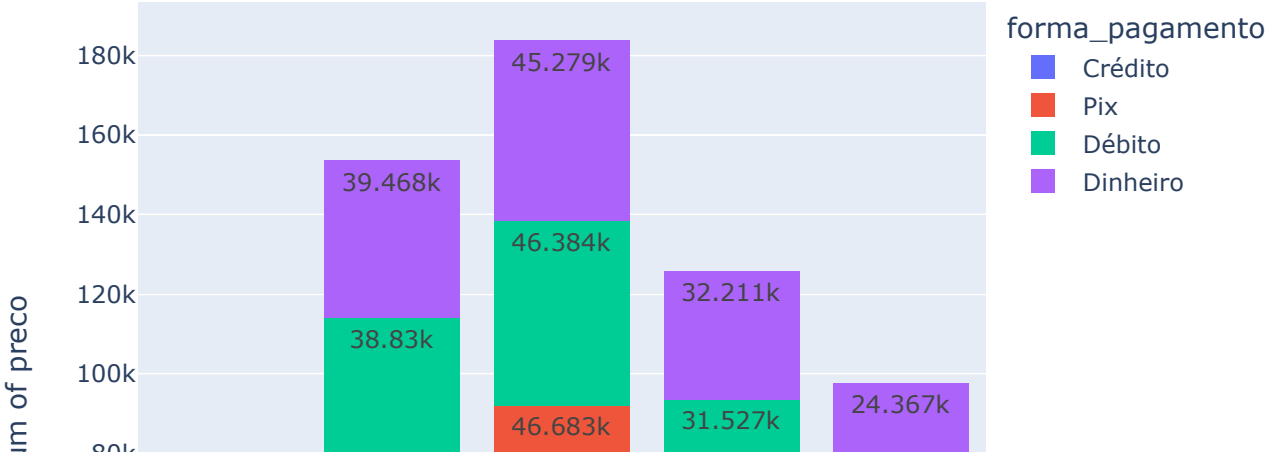
forma_pagamento
Crédito
Pix
Débito
Dinheiro
180k
160k
140k
120k
100k
45.279k
39.468k
46.384k
38.83k
46.683k
32.211k
31.527k
24.367k

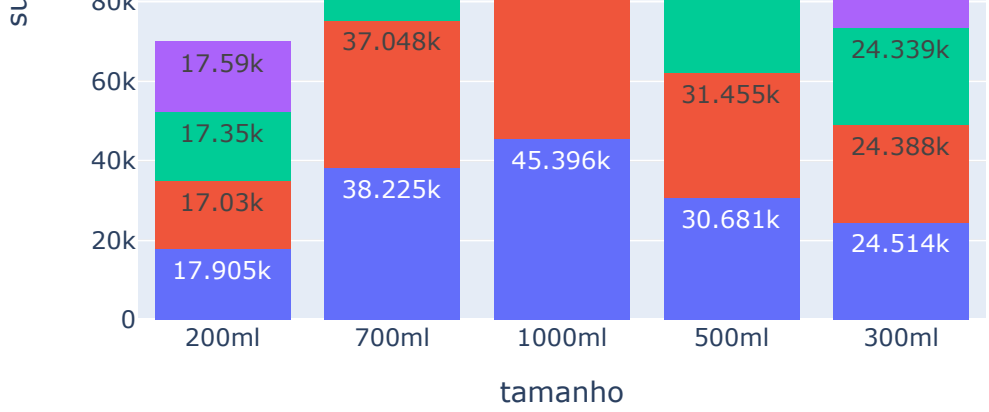

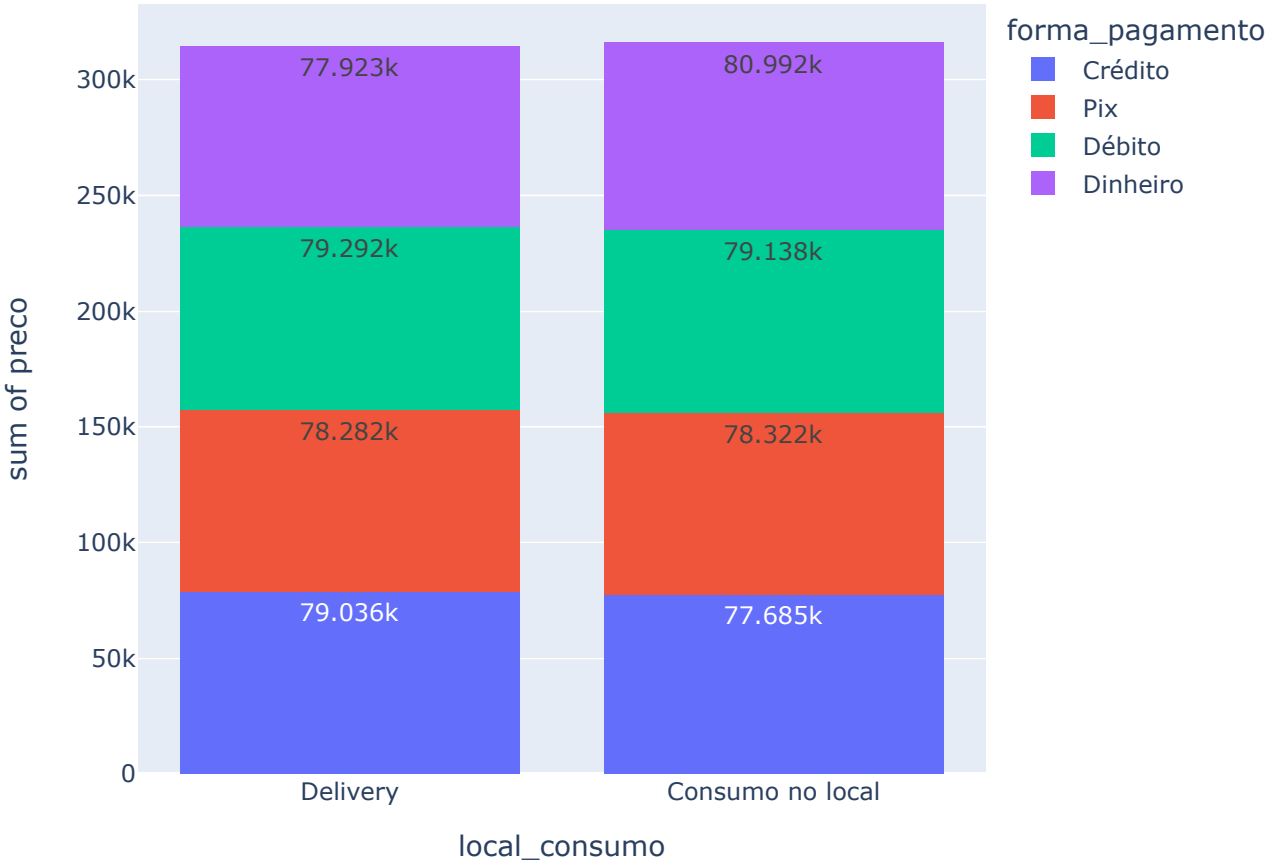

Gráfico animado

In [19]:
```
# agrupando os dados
agrupado = dados.groupby(['loja', 'ano_mes']).sum()

#resetando os índices
agrupado.reset_index(inplace=True)

# criando uma coluna com o valor acumulado
agrupado['acumulado'] = agrupado.groupby('loja').cumsum()
```

In [20]:
```
# gerando o gráfico
fig = px.bar(agrupado,
             x='acumulado',
```

```
            y="loja",
            color='loja',
            text_auto=True,
            range_x=[0,160000],
            animation_frame='ano_mes')
fig.show()
```

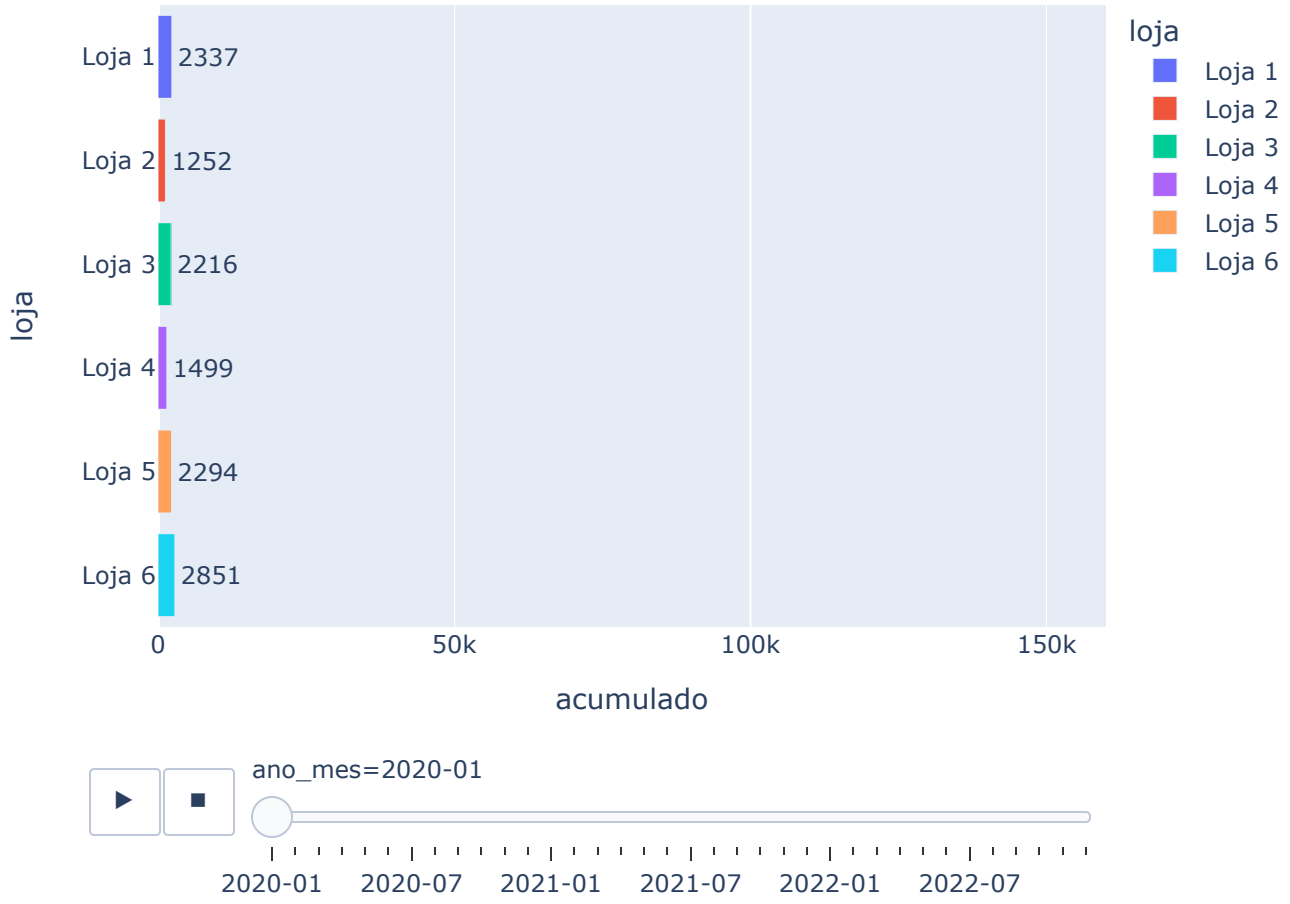

In [21]:
```
# exportando o gráfico para um arquivo
fig.write_html('grafico_animado.html')
```